Üniversite Öğrencilerinin Akademik Başarılarının Makine Öğrenmesi ile Tahmini: Özellik Analizi ve Grup Bazlı Model Performansının Değerlendirilmesi

Özet

Bu çalışmada, üniversite öğrencilerinin akademik başarılarının makine öğrenmesi yöntemleriyle tahmin edilmesi ve tahmin performansını etkileyebilecek değişkenlerin incelenmesi amaçlanmıştır. Çalışmada UCI Machine Learning Repository üzerinde yayımlanan Higher Education Students Performance Evaluation veri seti kullanılmıştır. Veri seti 145 öğrenci gözleminden oluşmakta ve akademik başarıyı FF, DD, DC, CC, CB, BB, BA ve AA olmak üzere sekiz not sınıfında temsil etmektedir.

Çalışma kapsamında öğrencilerin çalışma alışkanlıkları, önceki akademik başarıları, demografik ve sosyoekonomik özellikleri değerlendirilmiştir. Farklı özellik grupları karşılaştırılmış; Random Forest sınıflandırma algoritması kullanılarak model oluşturulmuş ve hiperparametre optimizasyonu Nested Cross-Validation yöntemiyle gerçekleştirilmiştir. Model performansı Accuracy, Balanced Accuracy ve Macro F1 metrikleriyle ölçülmüş, Dummy Classifier modeli referans olarak kullanılmıştır. Ayrıca permutation feature importance, özellik çıkarma deneyleri ve cinsiyet gruplarına göre performans analizi gerçekleştirilmiştir.

Nested Cross-Validation sonucunda Random Forest modelinin Accuracy değeri 0,283, Balanced Accuracy değeri 0,287 ve Macro F1 değeri 0,247 olarak elde edilmiştir. Model, Dummy Baseline sonuçlarını tüm değerlendirme metriklerinde aşmıştır. Bununla birlikte sınıf bazlı analizler, modelin bazı not sınıflarında başarılı olurken özellikle CB ve BA sınıflarında düşük performans gösterdiğini ortaya koymuştur.

Elde edilen bulgular, akademik başarı tahmininde birden fazla değişkenin birlikte değerlendirilmesinin önemini göstermektedir. Ancak veri setinin küçük olması, sınıf dağılımındaki dengesizlik ve model performansındaki değişkenlik nedeniyle sonuçların genellenebilirliği sınırlıdır.

Anahtar Kelimeler: Makine öğrenmesi, akademik başarı tahmini, Random Forest, özellik önemi, Nested Cross-Validation, sınıflandırma.

1. Giriş

Üniversite öğrencilerinin akademik başarılarını etkileyen faktörlerin incelenmesi, eğitim süreçlerinin değerlendirilmesi ve öğrencilere yönelik destek mekanizmalarının geliştirilmesi açısından önem taşımaktadır. Öğrencilerin akademik performansı yalnızca ders çalışma süresiyle değil; önceki akademik başarı, derslere katılım, öğrenme alışkanlıkları, sosyoekonomik koşullar ve demografik özellikler gibi birçok değişkenle ilişkili olabilir.

Makine öğrenmesi algoritmaları, farklı değişkenler arasındaki örüntüleri inceleyerek tahmin modelleri oluşturulmasına olanak tanımaktadır. Bununla birlikte eğitim verilerinde sınıf dengesizliği, sınırlı gözlem sayısı ve değişkenler arasındaki ilişkiler model performansını etkileyebilmektedir.

Bu çalışmada üniversite öğrencilerinin akademik başarılarının tahmin edilmesi için Random Forest algoritması kullanılmıştır. Çalışmanın yalnızca tahmin doğruluğuna odaklanmaması; özellik önemini, değişken çıkarma deneylerini ve gruplar arasındaki model performansı farklılıklarını da incelemesi hedeflenmiştir.

2. Çalışmanın Amacı ve Araştırma Soruları

Çalışmanın temel amacı, öğrencilerin akademik başarılarını etkileyebilecek çeşitli özellikleri birlikte değerlendirerek makine öğrenmesi tabanlı bir sınıflandırma modeli geliştirmek ve modelin performansını farklı açılardan incelemektir.

Bu amaç doğrultusunda aşağıdaki araştırma soruları ele alınmıştır:

1. Öğrencilerin yalnızca çalışma alışkanlıkları kullanılarak akademik notları tahmin edilebilir mi?
2. Önceki akademik başarı bilgisinin modele eklenmesi tahmin performansını nasıl değiştirmektedir?
3. Demografik ve sosyoekonomik özelliklerin de kullanılması model performansına katkı sağlamakta mıdır?
4. Modelin tahminlerinde hangi değişkenler daha önemli görünmektedir?
5. Belirli değişkenlerin çıkarılması model performansını nasıl etkilemektedir?
6. Model farklı cinsiyet gruplarında benzer performans göstermekte midir?
7. Model hangi akademik not sınıflarını tahmin etmekte zorlanmaktadır?

3. Veri Seti

Çalışmada UCI Machine Learning Repository'de yayımlanan **Higher Education Students Performance Evaluation** veri seti kullanılmıştır.

Veri seti 145 öğrenci gözleminden oluşmaktadır. Akademik başarı hedef değişkeni `OUTPUT Grade` olarak tanımlanmıştır. Hedef değişken sekiz sınıftan oluşmaktadır:

Kod	Harf notu
0	FF
1	DD
2	DC
3	CC
4	CB
5	BB
6	BA
7	AA

Veri setinde öğrencilerin yaş ve cinsiyet gibi demografik özellikleri; burs türü, ebeveyn eğitim düzeyi ve barınma koşulları gibi sosyoekonomik özellikleri; çalışma saatleri, derslere katılım ve ders dinleme alışkanlıkları gibi eğitimle ilişkili özellikleri bulunmaktadır.

Veri setindeki değişkenler kategorik kodlarla temsil edildiğinden, bu kodların tümü sürekli sayısal ölçümler olarak değerlendirilmemiştir.

4. Yöntem

4.1. Veri hazırlama ve özellik grupları

Modelleme aşamasında hedef değişken `OUTPUT Grade` olarak belirlenmiştir. Geleceğe ilişkin bilgi içerebilme ihtimali nedeniyle `Expected Cumulative grade point average in the graduation (/4.00)` değişkeni ve doğrudan ders kimliğini temsil eden `Course ID` değişkeni nihai geniş profil modelinden çıkarılmıştır.

Farklı özellik gruplarının etkisini incelemek amacıyla üç deney profili oluşturulmuştur:

- **A – Çalışma alışkanlıkları:** 12 çalışma ve öğrenme alışkanlığı değişkeni.
- **B – Çalışma alışkanlıkları ve önceki akademik başarı:** A grubuna önceki dönem not ortalamasının eklenmesiyle 13 değişken.
- **C – Genişletilmiş öğrenci profili:** Belirtilen iki değişken çıkarıldıktan sonra kalan 29 tahmin değişkeni.

Kategorik değişkenlerin modele uygun biçimde aktarılması için OneHotEncoder kullanılmıştır. Kodlama ve sınıflandırma işlemleri Pipeline yapısı içerisinde birleştirilmiştir.

4.2. Kullanılan algoritma

Sınıflandırma algoritması olarak Random Forest tercih edilmiştir. Random Forest, birden fazla karar ağacının sonuçlarını birleştirerek sınıflandırma yapan topluluk öğrenmesi yöntemidir.

Modelin hiperparametreleri aşağıdaki seçenekler arasından aranmıştır:

- `n_estimators`: 100 ve 200
- `max_depth`: 3, 5 ve None
- `min_samples_leaf`: 2, 3 ve 5
- `class_weight`: None ve balanced

4.3. Nested Cross-Validation

Hiperparametre optimizasyonunun model değerlendirmesine yol açabileceği iyimser yanlılığı azaltmak amacıyla Nested Cross-Validation uygulanmıştır.

Dış çapraz doğrulamada 5 katlı StratifiedKFold, iç hiperparametre aramasında ise 3 katlı StratifiedKFold kullanılmıştır. Her dış kat içerisinde hiperparametre araması yalnızca ilgili eğitim verisi üzerinde gerçekleştirilmiş, ardından model dış test katında değerlendirilmiştir.

Bu yaklaşım, hiperparametre seçimi ile model performansının değerlendirilmesini birbirinden ayırmayı amaçlamaktadır.

4.4. Değerlendirme metrikleri

Model performansı üç temel metrikle değerlendirilmiştir:

- **Accuracy:** Tüm tahminler içerisindeki doğru tahmin oranı.
- **Balanced Accuracy:** Her sınıfın Recall değerlerinin ortalaması.
- **Macro F1:** Her sınıfın F1 değerinin eşit ağırlıkla ortalaması.

Sınıflar arasındaki örnek sayısı farklılıkları nedeniyle yalnızca Accuracy değerine dayanılmamış, Balanced Accuracy ve Macro F1 değerleri de dikkate alınmıştır.

Ek olarak DummyClassifier (`most_frequent`) modeli referans performans olarak kullanılmıştır.

5. Bulgular

5.1. Özellik gruplarının karşılaştırılması

İlk deneylerde çalışma alışkanlıkları, önceki akademik başarı ve genişletilmiş öğrenci profili karşılaştırılmıştır.

Deney	Özellik sayısı	Accuracy	Balanced Accuracy	Macro F1
A – Çalışma alışkanlıkları	12	0,152	0,142	0,127
B – Alışkanlıklar + önceki not ortalaması	13	0,221	0,177	0,169
C – Genişletilmiş öğrenci profili	29	0,283	0,252	0,232

Bu deneylerde genişletilmiş öğrenci profili en yüksek performans değerlerini vermiştir. Önceki dönem akademik başarı bilgisinin eklenmesi de A profiline kıyasla performans artışıyla ilişkilidir.

Bu bulgular, çalışma alışkanlıklarının tek başına akademik notları açıklamakta sınırlı kalabileceğini ve daha geniş bir değişken grubunun tahmin performansına katkı sağlayabildiğini göstermektedir.

Not: Bu tablo, sabit hiperparametrelerle yapılan önceki 5 katlı çapraz doğrulama deneylerini göstermektedir. Nested Cross-Validation sonuçları nihai değerlendirme için ayrıca raporlanmıştır.

5.2. Nested Cross-Validation ve baseline karşılaştırması

Nihai 29 değişkenli model Nested Cross-Validation yöntemiyle değerlendirilmiştir.

Model	Accuracy	Balanced Accuracy	Macro F1
Nested Random Forest	0,283	0,287	0,247
Dummy Baseline	0,241	0,125	0,049

Random Forest modeli üç metrikte de Dummy Baseline modelinden daha yüksek sonuç elde etmiştir. Özellikle Balanced Accuracy ve Macro F1 değerleri arasındaki fark, modelin yalnızca en sık görülen not sınıfını tahmin etmekten daha fazlasını yaptığını göstermektedir.

Bununla birlikte Accuracy değerinin 0,283 olması, modelin genel tahmin başarısının hâlâ sınırlı olduğunu ortaya koymaktadır.

Dış çapraz doğrulama katları arasındaki standart sapmalar şöyledir:

Metrik	Standart sapma
Accuracy	0,099
Balanced Accuracy	0,111
Macro F1	0,091

Bu değerler, farklı veri bölünmelerinde model performansının değişebildiğini göstermektedir.

5.3. Özellik önem analizi

Permutation Feature Importance yöntemi kullanılarak 29 değişkenli modelde özelliklerin tahmin performansına katkısı incelenmiştir. Bu yöntemde bir değişkenin değerleri karıştırıldığında model performansındaki düşüş ölçülmektedir.

En yüksek önem değerine sahip 10 değişken aşağıda verilmiştir:

Değişken	Permutation Importance
Scholarship type	0,0435
Sex	0,0401
Mother's education	0,0278
Accomodation type in Cyprus	0,0242
Cumulative grade point average in the last semester	0,0232
Weekly study hours	0,0198
Student Age	0,0180
Impact of your projects/activities on your success	0,0168
Attendance to the seminars/conferences related to the department	0,0129
Flip-classroom	0,0122

Sonuçlar, burs türü, cinsiyet, anne eğitim düzeyi ve barınma türü gibi değişkenlerin model tahminleri açısından öne çıktığını göstermektedir.

Bu değerler nedensel etkiyi veya değişkenin akademik başarıyı yüzde kaç açıkladığını göstermez. Yalnızca kullanılan model ve değerlendirme düzeninde değişkenlerin tahmin performansıyla ilişkili önemini ifade eder.

5.4. Özellik çıkarma (Ablation) analizi

Öne çıkan üç değişkenin model performansına katkısını incelemek amacıyla değişken çıkarma deneyleri gerçekleştirilmiştir.

Deney	Özellik sayısı	Accuracy	Balanced Accuracy	Macro F1
Tüm değişkenler	29	0,283	0,252	0,232
Sex çıkarıldı	28	0,228	0,184	0,164
Scholarship type çıkarıldı	28	0,228	0,215	0,193
Mother's education çıkarıldı	28	0,248	0,205	0,185
Üçü birlikte çıkarıldı	26	0,207	0,159	0,144

Üç değişkenin birlikte çıkarılması sonucunda bütün performans metriklerinde düşüş görülmüştür. Bu sonuç, söz konusu değişkenlerin mevcut modelin tahmin performansına katkı sağlayabildiğini göstermektedir.

Bununla birlikte özellik çıkarma deneyleri nedensellik kanıtı değildir. Değişkenler arasındaki ilişkiler ve diğer özelliklerle örtüşmeler sonuçları etkileyebilir.

5.5. Cinsiyet gruplarına göre performans analizi

Modelin gruplar arasında benzer performans gösterip göstermediğini incelemek amacıyla cinsiyet gruplarına göre değerlendirme yapılmıştır. Analiz, Nested Cross-Validation sonucunda her öğrenci için elde edilen dış kat tahminleri kullanılarak gerçekleştirilmiştir.

Sex kodu	Öğrenci sayısı	Accuracy	Balanced Accuracy	Macro F1
1	58	0,190	0,172	0,130
2	87	0,345	0,293	0,250

İki grup arasında performans farkı gözlenmiştir. Sex=2 grubunda üç metrik de daha yüksek bulunmuştur.

Bu fark, modelin gruplar arasında eşit performans göstermediğine işaret etmektedir. Ancak grupların not dağılımları, örneklem büyüklükleri ve diğer özellikleri farklı olabileceğinden, performans farkının yalnızca cinsiyet değişkeninden kaynaklandığı sonucuna varılamaz.

Ayrıca bu analiz tek başına modelin adil veya ayrımcı olduğunu kanıtlamaz. Sonuçlar, daha kapsamlı grup adaleti değerlendirmeleri için başlangıç niteliğindedir.

5.6. Sınıf bazlı performans analizi

Modelin sekiz not sınıfındaki tahmin performansı, dış çapraz doğrulama tahminleri birleştirilerek incelenmiştir.

Not	Precision	Recall	F1-score	Öğrenci sayısı
FF	0,278	0,625	0,385	8
DD	0,375	0,257	0,305	35
DC	0,304	0,292	0,298	24
CC	0,333	0,286	0,308	21
CB	0,000	0,000	0,000	10
BB	0,176	0,176	0,176	17
BA	0,091	0,077	0,083	13
AA	0,400	0,588	0,476	17

Modelin en yüksek F1 değeri AA sınıfında 0,476 olarak elde edilmiştir. FF sınıfında Recall 0,625'tir. Buna karşılık CB sınıfında hiçbir öğrenci doğru tahmin edilememiş, BA sınıfında ise Recall 0,077 olarak bulunmuştur.

Bu sonuçlar modelin not sınıflarının tamamında dengeli tahmin başarısı gösteremediğini ortaya koymaktadır. Özellikle CB ve BA sınıfları için daha fazla veri, farklı modelleme yaklaşımları ve sınıf dengesizliğini dikkate alan yöntemler araştırılabilir.

5.7. Confusion Matrix değerlendirmesi

Confusion Matrix sonuçları, modelin bazı sınıfları birbirleriyle karıştırdığını göstermektedir. Örneğin gerçek BA notuna sahip 13 öğrencinin yalnızca biri doğru sınıflandırılmıştır. Gerçek CB notuna sahip 10 öğrencinin ise hiçbiri doğru sınıflandırılamamıştır.

Gerçek AA notuna sahip 17 öğrencinin 10'unun doğru tahmin edilmesi, modelin bu sınıfta görece daha başarılı olduğunu göstermektedir.

Bu bulgular, genel Accuracy değerinin tek başına model davranışını açıklamak için yeterli olmadığını desteklemektedir.

6. Tartışma

Çalışmada elde edilen sonuçlar, akademik başarı tahmininde çalışma alışkanlıklarının yanında önceki akademik başarı, demografik ve sosyoekonomik özelliklerin de değerlendirilmesinin yararlı olabileceğini göstermektedir.

Genişletilmiş öğrenci profili, yalnızca çalışma alışkanlıklarını içeren profile göre daha yüksek performans göstermiştir. Özellik önem analizinde burs türü, cinsiyet ve anne eğitim düzeyi gibi değişkenlerin öne çıkması, akademik başarı tahmininin birden fazla özellik grubuyla ilişkili olabileceğine işaret etmektedir.

Bununla birlikte modelin genel başarısı sınırlıdır. Sınıf bazlı sonuçlarda bazı notların doğru tahmin edilme oranları oldukça düşüktür. Bu durum, küçük veri seti ve sınıf dağılımındaki dengesizlik gibi faktörlerle ilişkili olabilir.

Cinsiyet gruplarındaki performans farklılığı da dikkatle ele alınmalıdır. Bu farkın nedenlerini açıklayabilmek için daha büyük ve farklı öğrenci gruplarını kapsayan veri setleriyle ek çalışmalar yapılması gerekmektedir.

7. Sınırlılıklar

Bu çalışmanın başlıca sınırlılıkları şunlardır:

1. Veri seti yalnızca 145 gözlemden oluşmaktadır. Bu büyüklük, sekiz sınıflı bir problem için sınırlıdır.
2. Sınıfların örnek sayıları dengeli değildir. Bazı not sınıflarında çok az sayıda öğrenci bulunmaktadır.
3. Veri seti belirli bir üniversite ve öğrenci grubuna dayanmaktadır. Bu nedenle sonuçlar tüm üniversite öğrencilerine genellenemez.
4. Random Forest modeli her not sınıfında aynı başarıyı göstermemiştir.
5. Çapraz doğrulama katları arasında performans değişkenliği gözlenmiştir.
6. Özellik önem değerleri nedensel ilişki göstermez.
7. Grup bazlı performans analizleri sınırlı örneklem büyüklükleri nedeniyle ihtiyatlı yorumlanmalıdır.

8. Sonuç ve Gelecek Çalışmalar

Bu çalışmada üniversite öğrencilerinin akademik notlarının makine öğrenmesi yöntemleriyle tahmin edilmesi amacıyla Random Forest tabanlı bir sınıflandırma modeli geliştirilmiştir. Çalışma kapsamında farklı özellik grupları karşılaştırılmış, Nested Cross-

Validation ile hiperparametre optimizasyonu değerlendirilmiş, özellik önem analizi, özellik çıkarma deneyleri ve grup bazlı performans incelemesi gerçekleştirilmiştir.

Nested Cross-Validation sonucunda model 0,283 Accuracy, 0,287 Balanced Accuracy ve 0,247 Macro F1 değerlerine ulaşmıştır. Modelin Dummy Baseline yöntemini tüm metriklerde aşması olumlu bir bulgudur. Bununla birlikte sınıf bazlı sonuçlar, özellikle CB ve BA notlarında tahmin performansının yetersiz kaldığını göstermektedir.

Gelecek çalışmalarda daha büyük ve farklı üniversitelerden elde edilen veri setlerinin kullanılması, farklı sınıflandırma algoritmalarının karşılaştırılması, sınıf dengesizliğine yönelik yöntemlerin araştırılması ve grup bazlı performans farklarının daha kapsamlı değerlendirilmesi önerilmektedir.

Sonuç olarak bu çalışma, akademik başarı tahmininin çok boyutlu yapısını inceleyen ve yalnızca genel doğruluğa değil, özellik katkılarına ve model performansındaki grup farklılıklarına da odaklanan keşifsel bir makine öğrenmesi uygulamasıdır.

Kaynakça

UCI Machine Learning Repository. *Higher Education Students Performance Evaluation*. Veri seti. https://archive.ics.uci.edu/

Not: Raporun son hâlini teslim etmeden önce veri setinin tam kaynak sayfası, erişim tarihi ve varsa dersin istediği akademik kaynak gösterim biçimi eklenmelidir.